



دانشگاه صنعتی امیرکبیر

(پلی‌تکنیک تهران)

دانشکده ریاضی و علوم کامپیوتر

درس هوش مصنوعی و کارگاه

گزارش ۶: خوشه‌بندی دیتاست Iris با کمک الگوریتم ژنتیک

نگارش

مهرسا گودرزی

۹۹۱۲۰۴۳

استاد اول

دکتر مهدی قطعی

استاد دوم

بهنام یوسفی مهر

۱۴۰۲ دی

چکیده

خوشبندی داده‌ها یکی از روش‌های مهم تجزیه و تحلیل داده‌ها است که به دسته‌بندی داده‌ها بر اساس شباهت‌های آن‌ها می‌پردازد. در این مقاله، ما دو روش خوشبندی K-Means و الگوریتم ژنتیک را بر روی دیتاست Iris که شامل اطلاعات درباره گونه‌های مختلف گل زنبق است، اعمال کرده و نتایج آن‌ها را با هم مقایسه می‌کنیم. هدف ما از این مقاله، درک درست از الگوریتم ژنتیک و نحوه حل مسئله خوشبندی به کمک این الگوریتم می‌باشد. با توجه به این که درصد درستی خوشبندی به نحوه تعریف توابع ما در الگوریتم ژنتیک بستگی دارد، بالا بودن دقت خوشبندی هدف ما در اینجا نمی‌باشد.

واژه‌های کلیدی:

خوشبندی، K-means، Iris، الگوریتم ژنتیک

صفحه

فهرست مطالعه

| | |
|----|--|
| ۱ | چکیده |
| ۲ | فصل اول مقدمه |
| ۳ | فصل دوم خوشه‌بندی K-means |
| ۴ | ۱- آماده‌سازی داده |
| ۵ | ۲- الگوریتم K-means |
| ۶ | ۳- تحلیل نتایج خوشه‌بندی K-Means |
| ۷ | ۴-۱- ماتریس پیش‌بینی |
| ۸ | ۴-۲- Purity Score |
| ۹ | فصل سوم خوشه‌بندی با استفاده از الگوریتم ژنتیک |
| ۱۰ | ۱- جمعیت اولیه |
| ۱۱ | ۲- تابع Fitness |
| ۱۲ | ۳- تابع Selection |
| ۱۳ | ۴- تابع Mutation |
| ۱۴ | ۵- تابع Crossover |
| ۱۵ | ۶- سیر تکامل |
| ۱۶ | ۷-۱- ارزیابی الگوریتم ژنتیک |
| ۱۷ | ۷-۲- ارزیابی الگوریتم ژنتیک |
| ۱۸ | فصل چهارم لینک کد گزارش |
| ۱۹ | فصل پنجم جمع‌بندی و نتیجه‌گیری |
| ۲۰ | منابع |

صفحه

فهرست اشکال

| | |
|----|---|
| ۵ | شکل ۲-۱- تعریف متغیرهای target_labels و basic_samples |
| ۶ | شکل ۲-۲- نرمال سازی نمونه ها و اعمال PCA بر روی آن ها |
| ۶ | شکل ۲-۳- تصویر کد الگوریتم K-means |
| ۷ | شکل ۲-۴- تصویر کد مربوط به بصری سازی نتایج خوشبندی K-means |
| ۷ | شکل ۲-۵- نمودار بصری سازی نتایج خوشبندی K-means |
| ۸ | شکل ۲-۶- تصویر کد مربوط به K-means Contingency Matrix و جزئیات آن |
| ۹ | شکل ۲-۷- جزئیات به دست آمده از K-Means Contingency Matrix |
| ۹ | شکل ۲-۸- محاسبه K-Means Purity Score |
| ۱۲ | شکل ۳-۱- تصویر کد دوتابع generate_population و random_chromosome |
| ۱۳ | شکل ۳-۲- کد تابع fitness |
| ۱۴ | شکل ۳-۳- تصویر کد تابع selection |
| ۱۵ | شکل ۳-۴- تصویر کد تابع mutation |
| ۱۷ | شکل ۳-۵- تصویر کد تابع crossover |
| ۱۸ | شکل ۳-۶- تصویر کد حلقه اصلی الگوریتم ژنتیک |
| ۱۸ | شکل ۳-۷- روند تغییر مقدار Fitness بهترین کروموزوم هر نسل |
| ۱۹ | شکل ۳-۸- نمودار بصری سازی نتایج خوشبندی به کمک الگوریتم ژنتیک |
| ۲۰ | شکل ۳-۹- جزئیات به دست آمده از Genetic Contingency Matrix |
| ۲۰ | شکل ۳-۱۰- محاسبه Genetic Purity Score |

فصل اول

مقدمه

مقدمه

دیتاست Iris یک مجموعه داده مشهور و کلاسیک در حوزه یادگیری ماشین^۱ و داده‌کاوی^۲ است که شامل اطلاعاتی در مورد سه گونه مختلف از گل‌های زنبق است: زنبق نوک‌زبر^۳، زنبق رنگارنگ^۴ و زنبق ویرجینیا^۵. این دیتاست توسط رونالد فیشر^۶، یک آماردان و زیست‌شناس بریتانیایی، در سال ۱۹۳۶ معرفی شد. هر گل زنبق در این دیتاست با چهار ویژگی توصیف می‌شود: طول و عرض کاسبرگ و طول و عرض گلبرگ. هدف از این دیتاست این است که بتوان با استفاده از این ویژگی‌ها، گل‌های زنبق را به سه گونه موجود طبقه‌بندی کرد.

خوشبندی^۷ داده‌ها یکی از روش‌های مهم تجزیه و تحلیل داده‌ها است که به دسته‌بندی داده‌ها بر اساس شباهت‌های آن‌ها می‌پردازد. برای خوشبندی دیتاست Iris، می‌توان از روش‌های مختلفی مانند K-Means و الگوریتم ژنتیک^۸ استفاده کرد.

الگوریتم K-Means یکی از روش‌های پرکاربرد و ساده خوشبندی است که بر اساس فاصله اقلیدسی بین نقاط داده و مراکز خوشبدها عمل می‌کند. این الگوریتم با تعیین تعداد خوشبدها به صورت از پیش تعیین شده، به طور تکراری مراکز خوشبدها را بهینه می‌کند تا مجموع مربعات فاصله‌ها کمینه شود. الگوریتم K-Means سریع و ساده است اما ممکن است در برخی موارد به حداقل محلی گیر کند یا به تعداد خوشبدها حساس باشد.

^۱ Machine Learning

^۲ Data Mining

^۳ Iris Setosa

^۴ Iris Versicolor

^۵ Iris Virginica

^۶ Ronald Fisher

^۷ Clustering

^۸ Genetic Algorithm

الگوریتم ژنتیک یک روش جستجوی ابتکاری و بهینه‌سازی است که از نظریه انتخاب طبیعی الهام گرفته شده است. این الگوریتم با شبیه‌سازی فرایند تکامل در طبیعت، با هدف یافتن بهترین جواب ممکن برای یک مسئله، به جستجو در فضای جواب‌های کاندید می‌پردازد. الگوریتم ژنتیک می‌تواند برای خوش‌بندی داده‌ها نیز استفاده شود. در این روش، هر جواب کاندید یا کروموزوم، یک تقسیم‌بندی از داده‌ها به خوش‌ها را نشان می‌دهد. این الگوریتم با اعمال عملگرهای ژنتیکی مانند جهش^۹، انتخاب^{۱۰} و ترکیب^{۱۱}، جمعیتی از کروموزوم‌ها را تولید می‌کند که با توجه به تابع هدف^{۱۲} یا تابع برازش^{۱۳}، بهترین تقسیم‌بندی را انتخاب می‌کند. الگوریتم ژنتیک مزایایی مانند تنوع و انعطاف‌پذیری دارد اما معایبی مانند پیچیدگی و زمان بر بودن نیز دارد.

در ادامه، ما برخی از جزئیات پیاده‌سازی و نتایج آن را ارائه می‌دهیم.

^۹ Mutation

^{۱۰} Selection

^{۱۱} Crossover

^{۱۲} Objective Function

^{۱۳} Fitness Function

فصل دوم

K-means خوشبندی

خوشبندی K-means

در این فصل برای خوشبندی دیتاست Iris از روش K-means استفاده می‌کنیم. برای این کار ابتدا دیتاست را بارگیری و سپس ساختار داده و اطلاعات موجود را بررسی می‌کنیم. سپس از الگوریتم استفاده می‌کنیم و به بررسی خوشها و تحلیل نتایج به دست آمده از این روش می‌پردازیم.

۱-۲ - آماده‌سازی داده

برای بارگیری اطلاعات موجود در Dataset می‌توان از کتابخانه Pandas استفاده کرد. با کمک توابع مختلف این کتابخانه، ما می‌توانیم ساختار کلی داده را ببینیم؛ این مجموعه داده شامل ۴ ویژگی مختلف است که نشان‌دهنده طول و عرض کاسبرگ و طول و عرض گلبرگ هستند. در ستون class این دیتاست که نشان‌دهنده نوع گل است، سه نوع گل متفاوت داریم که هر کدام ۵۰ نمونه را شامل می‌شوند. پس در کل این مجموعه داده شامل ۵ ستون و ۱۵۰ سطر است.

حال می‌خواهیم که نمونه‌های خود و برچسب‌ها که هدف ما برای تحلیل نتایج هستند به صورت متغیرهای جدا ذخیره کنیم. نمونه‌ها را که شامل ویژگی‌های داده هستند در متغیر basic_samples و برچسب‌ها در متغیر target_labels ذخیره می‌شوند. تصویر کد این بخش در شکل ۱-۲ آورده شده است.

```
basic_samples = iris_data.drop(columns='class')
target_labels = iris_data['class'].ravel()
```

شکل ۱-۲ - تعریف متغیرهای target_labels و basic_samples

بعد از تعریف این متغیرها و مشخص کردن samples و target به نرمال‌سازی نمونه‌ها و سپس کاهش بعد آن‌ها با کمک PCA می‌پردازیم. همان‌طور که در شکل ۲-۲ آورده شده است، ما با کمک کلاس sklearn.preprocessing StandardScaler از کتابخانه از گونه‌ای تغییر می‌دهیم که دارای میانگین ۰ و واریانس ۱ شوند. سپس با کمک کلاس PCA از کتابخانه sklearn.decomposition بعد داده‌ها را به ۲ کاهش می‌دهیم. در واقع PCA یک روش کاهش بعد است که برای کاهش تعداد متغیرهای یک داده بزرگ استفاده می‌شود. هدف از این کار این

است که با حفظ بیشترین اطلاعات ممکن در داده، آن را به یک داده کوچک‌تر تبدیل کنیم. برای این کار، PCA از یک تبدیل خطی استفاده می‌کند که داده را به یک سیستم مختصات جدید (مؤلفه‌های اصلی) منتقل می‌کند که در آن جهت‌هایی که بیشترین تغییرات را در داده نشان می‌دهند، به راحتی قابل شناسایی هستند.

```
normalized_samples = StandardScaler().fit_transform(basic_samples)
samples_pca = PCA(n_components=2).fit_transform(normalized_samples)
```

شكل ۲-۲- نرمال‌سازی نمونه‌ها و اعمال PCA بر روی آن‌ها

با انجام تمامی این کارها، داده‌های ما برای ورود به الگوریتم K-means آماده شده‌اند.

۲-۲ - الگوریتم K-means

برای پیاده‌سازی الگوریتم K-means بر روی داده‌های خود، از کتابخانه `sklearn.cluster` کمک می‌گیریم. کلاس `KMeans` با گرفتن ورودی‌های لازم، به راحتی می‌تواند خوشبندی را انجام دهد. از `KMeans` در `n_clusters` می‌خواهیم نمونه‌های خود را به سه خوش‌بندی تقسیم کنیم، ورودی `n_clusters` را برابر با ۳ قرار می‌دهیم. همچنین برچسب‌های مربوط به نتایج خوشبندی K-means را در متغیر `kmeans_labels` ذخیره می‌کنیم. تصویر کد این بخش در شکل ۲-۳ آورده شده است.

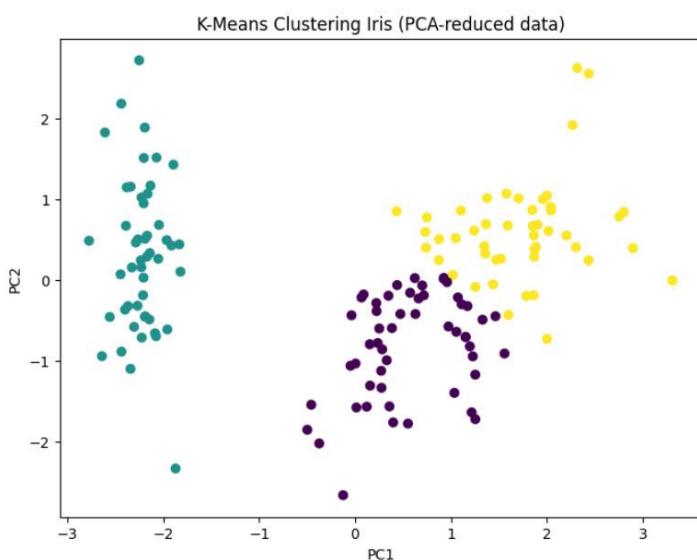
```
kmeans = KMeans(init='k-means++', n_clusters=3, n_init=10, random_state=42)
kmeans.fit(samples_pca)
kmeans_labels = kmeans.predict(samples_pca)
```

شکل ۲-۳- تصویر کد الگوریتم K-means

برای بصری‌سازی نتایج خوشبندی K-means از کتابخانه `matplotlib.pyplot` استفاده کنیم. این نمودار نحوه توزیع نمونه‌ها بر اساس PCA را نشان می‌دهد و برای مشخص کردن نحوه خوشبندی، از رنگ جداگانه برای هر خوش‌بندی استفاده کرده است. کد این بخش در شکل ۴-۲ و رسم نمودار مربوطه در شکل ۵-۲ دیده می‌شود. همان‌طور که به صورت شهودی نیز دیده می‌شود، تعداد داده‌های موجود در سه خوش‌بندی تفاوت زیادی با یکدیگر ندارند، بنابراین می‌توان پیش‌بینی کرد که خوشبندی ما کیفیت نسبتاً خوبی دارد.

```
plt.figure(figsize=(8, 6))
plt.scatter(samples_pca[:, 0], samples_pca[:, 1], c=kmeans_labels)
plt.xlabel("PC1")
plt.ylabel("PC2")
plt.title("K-Means Clustering Iris (PCA-reduced data)")
plt.show()
```

شکل ۲-۴- تصویر کد مربوط به بصری‌سازی نتایج خوشبندی K-means



شکل ۲-۵- نمودار بصری‌سازی نتایج خوشبندی K-means

۲-۳- تحلیل نتایج خوشبندی K-Means

برای تحلیل و ارزیابی عملکرد الگوریتم خوشبندی K-means، چندین معیار متفاوت وجود دارد. از آنجا که داده‌های ما دارای برچسب هستند، می‌توان از معیار خلوص^۱ استفاده کرد. این معیار درصد نمونه‌هایی را که به درستی دسته‌بندی شده‌اند را نشان می‌دهد. فرمول آن به صورت زیر است:

$$Purity = \frac{1}{N} \sum_{i=1}^k max_j(n_{ij})$$

^۱ Purity Score

که در آن N تعداد کل نمونه‌ها، k تعداد کل دسته‌ها، n_{ij} تعداد نمونه‌هایی است که هم‌zman در دسته i و خوشه j قرار دارند و $\max_j(n_{ij})$ بیشترین تعداد نمونه‌هایی است که در دسته i و یکی از خوشه‌ها قرار دارند. به عبارت دیگر، ما برای هر دسته، خوشه‌ای را انتخاب می‌کنیم که بیشترین اشتراک با آن دسته را دارد و سپس تعداد نمونه‌های مشترک را جمع می‌کنیم. سپس این مقدار را بر تعداد کل نمونه‌ها تقسیم می‌کنیم تا معیار خلوص را به دست آوریم. این معیار بین صفر و یک متغیر است و هر چه بیشتر باشد نشان‌دهنده‌ی کیفیت بالاتر خوشبندی است. در ادامه نحوه پیاده‌سازی این معیار در کد را توضیح می‌دهیم.

۱-۳-۲ - ماتریس پیشايندی

ماتریس پیشايندی یا Contingency Matrix در خوشبندی یک ماتریسی است که نشان می‌دهد که چه تعداد از نمونه‌های داده‌ها که دسته‌های واقعی آن‌ها مشخص است، به چه خوشه‌هایی توسط الگوریتم خوشبندی تخصیص داده شده‌اند. این ماتریس می‌تواند عملکرد الگوریتم خوشبندی را ارزیابی کند و بگوید که چقدر دقیق است.

برای محاسبه این ماتریس بر روی داده‌های خود، می‌توانیم از کتابخانه `sklearn.metrics.cluster` استفاده کنیم. در شکل ۲-۶ کد این بخش و در شکل ۷-۲ جزئیات به دست آمده از `Contingency Matrix` نشان داده شده است.

```
k_conting_matrix = cluster.contingency_matrix(labels_true=target_labels, labels_pred=kmeans_labels)
print(f"K-Means Contingency Matrix: \n{k_conting_matrix}")
print()

for i in range(len(k_conting_matrix)):
    for j in range(len(k_conting_matrix[i])):
        print(f"(Actual Label: {label_names[i]}, Predicted Label: {j}) = {k_conting_matrix[i][j]}")
```

شکل ۲-۶- تصویر کد مربوط به K-means Contingency Matrix و جزئیات آن

```

K-Means Contingency Matrix:
[[ 0 50  0]
 [39  0 11]
 [14  0 36]]

(Actual Label: Iris-setosa, Predicted Label: 0) = 0
(Actual Label: Iris-setosa, Predicted Label: 1) = 50
(Actual Label: Iris-setosa, Predicted Label: 2) = 0
(Actual Label: Iris-versicolor, Predicted Label: 0) = 39
(Actual Label: Iris-versicolor, Predicted Label: 1) = 0
(Actual Label: Iris-versicolor, Predicted Label: 2) = 11
(Actual Label: Iris-virginica, Predicted Label: 0) = 14
(Actual Label: Iris-virginica, Predicted Label: 1) = 0
(Actual Label: Iris-virginica, Predicted Label: 2) = 36

```

شکل ۷-۲- جزئیات به دست آمده از K-Means Contingency Matrix

Purity Score - ۴-۳-۲

تصویر کد محاسبه معیار خلوص یا همان Purity Score و مقدار آن در شکل ۸-۲ آورده شده است.

```

kmeans_clustering_purity = np.sum((np.max(k_conting_matrix, axis=1))) / np.sum(k_conting_matrix)
print(f"K-Means Clustering Purity: {kmeans_clustering_purity}")

K-Means Clustering Purity: 0.8333333333333334

```

شکل ۸-۲- محاسبه K-Means Purity Score

پس مقدار Purity Score حدودا برابر با 0.83 شد که این نشان دهنده آن است که الگوریتم خوشبندی K-means ما عملکرد نسبتا خوبی دارد اما به طور کاملا درست نمی تواند خوشبندی را انجام دهد.

فصل سوم

خوشبندی با استفاده از الگوریتم ژنتیک

خوشبندی با استفاده از الگوریتم ژنتیک

در این فصل برای خوشبندی دیتاست Iris از الگوریتم ژنتیک استفاده می‌کنیم. بارگیری و آماده‌سازی دیتا را از قبل انجام داده‌ایم. در ادامه اجزای این الگوریتم را توضیح می‌دهیم.

۳-۱-۱- جمعیت اولیه

در اینجا ما دوتابع generate_population و random_chromosome تعریف کرده‌ایم که این دو کمک می‌کنند که یک جمعیت اولیه از کروموزوم‌ها را برای حل مسئله خوشبندی دیتاست Iris ایجاد کنیم.

تابع random_chromosome یک کروموزوم تصادفی با طول ۱۵۱ عنصر ایجاد می‌کند. این کروموزوم نشان‌دهنده یک جواب کاندید برای مسئله خوشبندی دیتاست Iris است. هر کدام از ۱۵۰ عنصر اول کروموزوم یک عدد صحیح بین ۰ تا ۲ است که نشان‌دهنده برچسب خوشباهی است که به نمونه متناظر تخصیص داده شده است. برای مثال، اگر عنصر اول کروموزوم برابر با ۱ باشد، به این معنی است که نمونه اول دیتاست Iris به خوشة ۱ تعلق دارد. عنصر آخر کروموزوم یک عدد اعشاری است که نشان‌دهنده میزان سازگاری (fitness) آن کروموزوم است. میزان سازگاری یک کروموزوم نشان‌دهنده عملکرد آن کروموزوم در حل مسئله است و معمولاً با استفاده از یک تابع هدف محاسبه می‌شود. در ابتدا میزان سازگاری هر کروموزوم را برابر با صفر قرار می‌دهیم و بعداً با استفاده از تابع Fitness آن را به روزرسانی می‌کنیم. برای ایجاد یک کروموزوم تصادفی، از تابع randint از کتابخانه numpy استفاده می‌کنیم که یک آرایه از اعداد صحیح تصادفی با مقادیر و اندازه مشخص را برمی‌گرداند. سپس با استفاده از تابع append از همان کتابخانه، عنصر صفر را به انتهای آرایه اضافه می‌کنیم و کروموزوم را برمی‌گردانیم.

تابع generate_population یک جمعیت از کروموزوم‌ها را با استفاده از تابع random_chromosome ایجاد می‌کند. این جمعیت شامل تعداد مشخصی از کروموزوم‌ها است که به عنوان پارامتر به تابع داده می‌شود. برای مثال، اگر تعداد کروموزوم‌ها برابر با ۱۰۰۰ باشد، این تابع یک جمعیت از ۱۰۰۰ کروموزوم تصادفی را تولید می‌کند. برای ایجاد یک جمعیت، از یک حلقه for استفاده می‌کنیم که به تعداد کروموزوم‌ها، تابع random_chromosome را صدا می‌زنند و نتیجه را در یک آرایه numpy ذخیره می‌کنیم. سپس آرایه حاوی کروموزوم‌ها را برمی‌گردانیم.

تصویر کد این دو تابع در شکل ۳-۱ آورده شده است.

```
def random_chromosome():
    chromosome = np.random.randint(0, 3, size=150)
    # The last element of each chromosome indicates the fitness of that chromosome, which is initially set to zero
    chromosome = np.append(chromosome, 0.0)
    return chromosome

def generate_population(number_of_chromosomes):
    return np.array([random_chromosome() for _ in range(number_of_chromosomes)])
```

شکل ۳-۱- تصویر کد دو تابع `generate_population` و `random_chromosome`

بعد از تعریف این دو تابع، ما یک جمعیت اولیه از کروموزوم‌های تصادفی ایجاد می‌کنیم و تعداد اولیه این جمعیت را برابر با ۱۰۰۰ قرار می‌دهیم. این جمعیت اولیه در متغیری با نام `initial_population` ذخیره می‌شود.

۲-۳ - تابع Fitness

تابع `fitness` که تصویر کد آن در شکل ۲-۳ آورده شده است، به ما کمک می‌کند که میزان سازگاری یک کروموزوم را برای مسئله خوشبندی دیتاست Iris محاسبه کنیم. در این تابع، ابتدا یک لیست از شاخص‌های نمونه‌هایی که به هر یک از ۳ خوشه تعلق دارند ایجاد می‌کنیم. این کار با استفاده از تابع `where` از کتابخانه `numpy` انجام می‌شود که یک آرایه بولی را دریافت می‌کند و شاخص‌های عناصری را که `True` هستند را برمی‌گرداند. در اینجا ما از کروموزوم به عنوان آرایه بولی استفاده می‌کنیم و برای هر یک از مقادیر ۰ تا ۲، شاخص‌های نمونه‌هایی را پیدا می‌کنیم که با آن مقدار برابر هستند. نتیجه در متغیر `cluster_indices` ذخیره می‌شود.

سپس یک لیست از داده‌های نمونه‌هایی که به هر یک از ۳ خوشه تعلق دارند ایجاد می‌کنیم. این کار با استفاده از تابع `iloc` از کتابخانه `pandas` انجام می‌شود که یک شیء `DataFrame` را دریافت می‌کند و با استفاده از شاخص‌های عددی، سطرها یا ستون‌های مورد نظر را برمی‌گرداند. در اینجا ما از شیء `DataFrame` استفاده می‌کنیم و با استفاده از شاخص‌هایی که در مرحله قبل پیدا کردہ‌ایم، داده‌های نمونه‌های هر خوشه را انتخاب می‌کنیم. نتیجه در متغیر `clusters` ذخیره می‌شود.

در ادامه، تابع میانگین فاصله نمونه‌های هر خوشه از مرکز خوشه را محاسبه می‌کند. این کار با استفاده از تابع `mean` و تابع `linalg.norm` از کتابخانه `numpy` انجام می‌شود که به ترتیب میانگین و نرم یک

آرایه را محاسبه می‌کنند. در اینجا ما برای هر یک از سه خوش، فاصله نمونه‌ها را از میانگین ویژگی‌های خوش که نشان‌دهنده مرکز خوش است را با استفاده از نرم اقلیدسی محاسبه می‌کنیم و سپس میانگین این فاصله‌ها را برای هر خوش به دست می‌آوریم و نتیجه را در متغیر `differences` ذخیره می‌کنیم.

سپس تابع نسبت اندازه هر خوش به اندازه کل دیتاست را محاسبه می‌کند. در اینجا ما برای هر یک از سه خوش، تعداد نمونه‌های آن را تقسیم بر تعداد کل نمونه‌های دیتاست می‌کنیم و نسبت را به دست می‌آوریم و نتیجه را در متغیر `sizes` ذخیره می‌کنیم.

میزان سازگاری کروموزوم با استفاده از فرمول زیر محاسبه می‌شود:

$$\sum_{i=1}^k d_i \times s_i$$

که در آن k تعداد خوش‌ها، d_i میانگین فاصله نمونه‌های خوش i از مرکز خوش و s_i نسبت اندازه خوش i به اندازه کل دیتاست است. این فرمول نشان‌دهنده میزان پراکندگی داده‌ها در خوش‌ها است که هر چه کمتر باشد، نشان‌دهنده خوشبندی بهتر است. این کار را با استفاده از تابع `sum` و تابع `zip` از کتابخانه `numpy` انجام می‌شود. در اینجا ما مقادیر متغیرهای `differences` و `sizes` را با هم ضرب می‌کنیم و سپس جمع آن‌ها را محاسبه می‌کنیم و نتیجه را در متغیر `fitness_value` ذخیره می‌کنیم.

در نهایت مقدار متغیر `fitness_value` به عنوان خروجی تابع برگردانده می‌شود. این مقدار نشان‌دهنده میزان سازگاری کروموزوم با مسئله خوشبندی دیتاست Iris است که هر چه کمتر باشد، نشان‌دهنده کروموزوم بهتر است.

```
def fitness(chromosome):
    cluster_indices = [np.where(chromosome == i)[0] for i in range(3)]
    clusters = [iris_data.iloc[indices] for indices in cluster_indices]

    differences = [np.mean([np.linalg.norm(cluster[col] - cluster[col].mean()) for col in iris_data.columns[:-1]]) for cluster in clusters]
    sizes = [len(cluster) / len(iris_data) for cluster in clusters]

    fitness_value = sum(diff * size for diff, size in zip(differences, sizes))
    return fitness_value
```

شکل ۳-۲-۳- کد تابع `fitness`

در ادامه مقدار `fitness` را برای هر کروموزوم جمعیت اولیه محاسبه و آن را در آخرین عنصر هر کروموزوم جایگذاری می‌کنیم.

۳-۳- تابع Selection

تابع selection به ما کمک می‌کند که از میان یک جمعیت اولیه از کروموزوم‌ها، تعداد مشخصی از آن‌ها را به عنوان والدین برای تولید نسل بعدی انتخاب کنیم. این تابع دو پارامتر را دریافت می‌کند؛ پارامتر initial_population و پارامتر num. پارامتر initial_population یک جمعیت اولیه از کروموزوم‌ها و پارامتر num یک عدد صحیح است که نشان‌دهنده تعداد کروموزوم‌هایی است که می‌خواهیم به عنوان والدین انتخاب کنیم.

تابع selection با استفاده از تابع sorted از کتابخانه numpy، کروموزوم‌های جمعیت اولیه را بر اساس مقدار fitness آن‌ها مرتب می‌کند. برای مرتب‌سازی کروموزوم‌ها، از پارامتر key استفاده می‌کنیم که یک تابع لامبدا است که عنصر آخر هر کروموزوم را برمی‌گرداند. این کار باعث می‌شود که کروموزوم‌ها به صورت صعودی بر اساس مقدار fitness مرتب شوند.

تابع selection تعداد num عنصر اول آرایه مرتب شده را انتخاب می‌کند. با این کار، کروموزوم‌هایی که مقدار fitness بیشتری دارند، حذف شوند و کروموزوم‌هایی که مقدار fitness کمتری دارند، حفظ شوند. این کروموزوم‌های انتخاب شده، به عنوان والدین برای تولید نسل بعدی در نظر گرفته می‌شوند. در نهایت کروموزوم‌های انتخاب شده به عنوان خروجی برگردانده می‌شوند.

تصویر کد این تابع در شکل ۳-۳ قابل مشاهده است.

```
def selection(initial_population, num):
    return np.array(sorted(initial_population, key=lambda x: x[-1]))[:num]
```

شکل ۳-۳- تصویر کد تابع selection

در ادامه به کمک این تابع، دو کروموزوم که مقدار fitness کمتری دارند یعنی کاندید بهتری برای خوشبندی هستند را به عنوان والدین نسل بعدی انتخاب می‌کنیم و در همان متغیر initial_population ذخیره می‌کنیم.

۴-۳- تابع Mutation

تابع mutation یک کروموزوم را با احتمال مشخصی تغییر می‌دهد تا تنوع ژنتیکی را حفظ کند. این تابع دو پارامتر mutation_rate و chromosome را دریافت می‌کند. پارامتر mutation_rate یک عدد اعشاری بین ۰ تا ۱ است که نشان‌دهنده احتمال تغییر هر عنصر از کروموزوم است.

تابع mutation با استفاده از یک حلقه for، به ترتیب هر عنصر از کروموزوم را بررسی می‌کند که در اینجا با توجه به دیتاست Iris، ما ۱۵۰ عنصر را برای هر کروموزوم باید بررسی کنیم. این تابع با استفاده از تابع random.rand از کتابخانه numpy، یک عدد اعشاری تصادفی بین ۰ تا ۱ تولید می‌کند و آن را با مقدار mutation_rate مقایسه می‌کند. اگر عدد تصادفی کوچکتر از mutation_rate باشد، به این معنی است که تغییری در عنصر مورد نظر کروموزوم ایجاد شود. در غیر این صورت، عنصر کروموزوم بدون تغییر باقی می‌ماند. اگر عنصری باید تغییر داده شود، تابع mutation با استفاده از تابع random.randint از کتابخانه numpy، یک عدد صحیح تصادفی بین ۰ تا ۲ تولید می‌کند و آن را به عنوان مقدار جدید عنصر مورد نظر کروموزوم قرار می‌دهد. این کار باعث می‌شود که برچسب خوشه‌ای که به نمونه متناظر تخصیص داده شده است، تغییر کند. سپس در ادامه، کروموزوم تغییر یافته به عنوان خروجی تابع برگردانده می‌شود.

تصویر کد این تابع در شکل ۴-۳ آورده شده است.

```
def mutation(chromosome, mutation_rate):
    for i in range(150):
        if np.random.rand() < mutation_rate:
            chromosome[i] = np.random.randint(0, 3)
    return chromosome
```

شکل ۴-۳- تصویر کد تابع mutation

۵-۳- تابع Crossover

تابع crossover این تابع به ما کمک می‌کند که از میان یک جمعیت از کروموزوم‌ها، نسل جدیدی از کروموزوم‌ها را با کمک ترکیب و تغییر کروموزوم‌ها ایجاد کنیم. این کار باعث می‌شود که اطلاعات مفید

از والدین به فرزندان منتقل شود و تنوع ژنتیکی در جمعیت افزایش یابد. این تابع سه پارامتر population، cross_rate و mutation_rate را دریافت می‌کند. پارامتر population یک آرایه از کروموزوم‌ها است که نشان‌دهنده جمعیت فعلی است. پارامتر cross_rate یک عدد اعشاری بین ۰ تا ۱ است که نشان‌دهنده احتمال پیوند بین دو والد است. پارامتر mutation_rate یک عدد اعشاری بین ۰ تا ۱ است که نشان‌دهنده احتمال تغییر هر عنصر از یک کروموزوم است.

در ابتدا تابع crossover یک کپی از آرایه population را در متغیر new_population ذخیره می‌کند. این کپی برای نگهداری کروموزوم‌های جدید استفاده می‌شود. سپس با استفاده از دو حلقه for، همه جفت‌های ممکن از کروموزوم‌های جمعیت فعلی را بررسی می‌کند. این جفت‌ها به عنوان والدین برای تولید فرزندان در نظر گرفته می‌شوند و در ادامه با استفاده از یک حلقه for، دو فرزند از هر جفت والد تولید می‌شود.

تابع crossover با استفاده از تابع where از کتابخانه numpy، یک کروموزوم فرزند را با انتخاب تصادفی عناصر از دو کروموزوم والد ایجاد می‌کند. این کار با استفاده از یک آرایه از اعداد تصادفی بین ۰ تا ۱ انجام می‌شود که با مقدار cross_rate مقایسه می‌شوند. اگر عدد تصادفی کوچکتر از parent1 باشد، عنصر از کروموزوم parent2 انتخاب می‌شود. در غیر این صورت، عنصر از کروموزوم parent2 انتخاب می‌شود.

در ادامه، تابع با استفاده از تابع mutation، کروموزوم فرزند را با احتمال مشخصی تغییر می‌دهد و سپس کروموزوم فرزند را به آرایه new_population اضافه می‌کند. در نهایت آرایه new_population به عنوان خروجی تابع برگردانده می‌شود. این آرایه شامل کروموزوم‌های جمعیت فعلی و کروموزوم‌های جدید تولید شده است.

تصویر کد این تابع در شکل ۳-۵ نشان داده شده است.

```

def crossover(population, cross_rate, mutation_rate):
    new_population = population.copy()

    for parent1 in new_population:
        for parent2 in new_population:

            # Number of childs = 2
            for _ in range(2):
                child = np.where(np.random.rand() < cross_rate, parent1, parent2)
                child = mutation(child, mutation_rate)

            new_population = np.append(new_population, [child], axis=0)
    return new_population

```

شکل ۳-۵- تصویر کد تابع crossover

۳-۶- سیر تکامل

در ادامه الگوریتم ژنتیک کد مایک حلقه را اجرا می‌کند. این حلقه ۱۰۰۰ نسل از کروموزوم‌ها را تولید می‌کند و مقدار fitness بهترین کروموزوم هر نسل را ذخیره می‌کند. برای این کار ابتدا جمعیت اولیه کروموزوم‌ها در متغیر new_population کپی می‌شوند. سپس یک لیست خالی به نام best_fitness برای ذخیره مقدار fitness بهترین کروموزوم هر نسل ایجاد می‌شود. در ادامه در حلقه‌ای که ۱۰۰۰ بار تکرار می‌شود، به ترتیب مراحل زیر اجرا می‌شوند:

۱- پیوند دادن کروموزوم‌های جمعیت فعلی با cross_rate برابر با ۰.۵ و mutation_rate برابر با

۰.۰۵ و ایجاد نسل جدید

۲- محاسبه مقدار fitness هر کروموزوم جدید

۳- انتخاب دو کروموزوم برتر از جمعیت جدید

۴- افزودن مقدار fitness کروموزوم برتر جمعیت جدید به لیست best_fitness

بعد از اجرای این حلقه، لیست best_fitness چاپ می‌شود که نشان دهنده مقدار fitness بهترین کروموزوم در هر نسل است.

تصویر کد این قسمت در شکل ۳-۶ آورده شده است.

```

# Create an Empty List for the Best Fitness
new_population = initial_population.copy()
best_fitness = []

# Loop for 1000 Generations
for i in range(1000):
    # Perform Crossover on the Current Population
    new_population = crossover(new_population, 0.5, 0.05)
    # Calculate the Fitness for the New Population
    for chromosome in new_population:
        chromosome[-1] = fitness(chromosome[:-1])
    # Select the Best 2 individuals from the New Population
    new_population = selection(new_population, 2)
    best_fitness.append(new_population[0][-1])

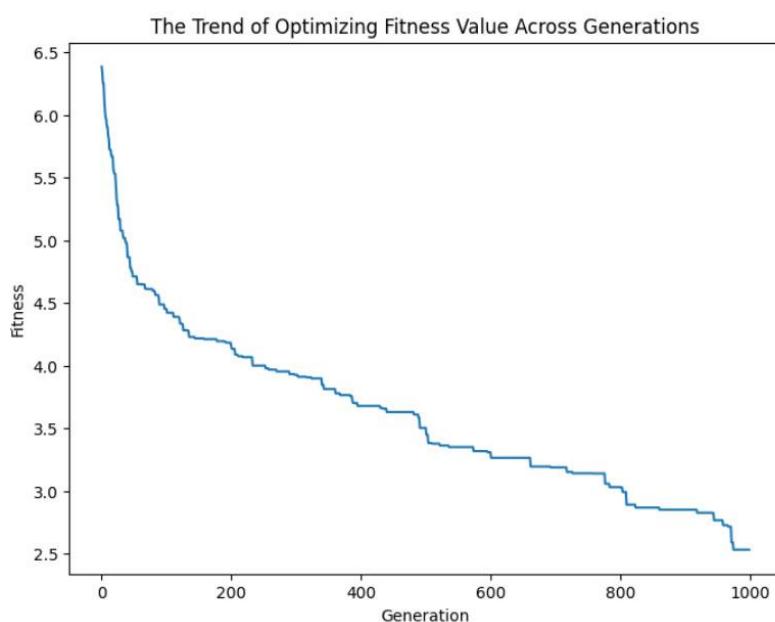
for i in range(len(best_fitness)):
    print(f"The Best Amount of Fitness in Generation {i}: {best_fitness[i]}")

```

شکل ۳-۶- تصویر کد حلقه اصلی الگوریتم ژنتیک

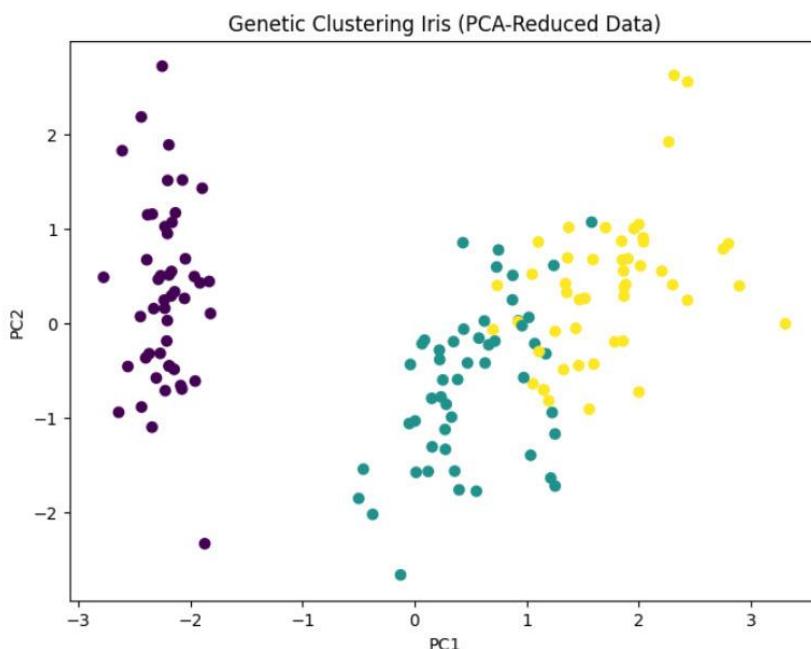
۷-۳- ارزیابی الگوریتم ژنتیک

همان طور که در شکل ۳-۷ دیده می‌شود، مقدار fitness بهترین کروموزوم هر نسل از نسل‌های قبلی کمتر است، که این به معنی آن است که آن کروموزوم کاندید بهتری برای خوشبندی است و نتایج بهتری را می‌تواند ارائه بدهد.



شکل ۳-۷- روند تغییر مقدار Fitness بهترین کروموزوم هر نسل

بنابراین ما بهترین کروموزوم آخرین نسل را به عنوان کandid خوشبندی خود انتخاب و آن را در یک متغیر به نام `best_solution` ذخیره می‌کنیم. این متغیر شامل برچسب‌های پیش‌بینی شده برای خوشبندی می‌باشد. نمودار پراکندگی و نحوه خوشبندی الگوریتم ژنتیک با توجه به متغیر `best_solution`، در شکل ۸-۳ نشان داده شده است. همان‌طور که به صورت شهودی از این نمودار می‌توان برداشت کرد، خوشبندی ما به کمک الگوریتم ژنتیک عملکرد نسبتاً خوبی داشته است.



شکل ۸-۳- نمودار بصری‌سازی نتایج خوشبندی به کمک الگوریتم ژنتیک

نحوه محاسبه `Purity Score` و `Contingency Matrix` مانند الگوریتم خوشبندی K-Means است. در شکل ۹-۳ جزئیات `Genetic Contingency Matrix` و در شکل ۱۰-۳ مقدار محاسبه شده آورده شده است. `Genetic Purity Score`

```

Genetic Contingency Matrix:
[[50  0  0]
 [ 0 43  7]
 [ 0  8 42]]

(Actual Label: Iris-setosa, Predicted Label: 0) = 50
(Actual Label: Iris-setosa, Predicted Label: 1) = 0
(Actual Label: Iris-setosa, Predicted Label: 2) = 0
(Actual Label: Iris-versicolor, Predicted Label: 0) = 0
(Actual Label: Iris-versicolor, Predicted Label: 1) = 43
(Actual Label: Iris-versicolor, Predicted Label: 2) = 7
(Actual Label: Iris-virginica, Predicted Label: 0) = 0
(Actual Label: Iris-virginica, Predicted Label: 1) = 8
(Actual Label: Iris-virginica, Predicted Label: 2) = 42

```

شکل ۳-۹- جزئیات به دست آمده از Genetic Contingency Matrix

```

genetic_clustering_purity = np.sum((np.max(gen_conting_matrix, axis=1))) / np.sum(gen_conting_matrix)
print(f"Genetic Clustering Purity: {genetic_clustering_purity}")

Genetic Clustering Purity: 0.9

```

شکل ۳-۱۰- محاسبه Genetic Purity Score

مقدار Purity Score برای خوشبندی الگوریتم ژنتیک ما برابر با ۰.۹ شده است که نشان دهندهی عملکرد خوب این الگوریتم در مسئله خوشبندی می‌باشد. با توجه به نقش اعداد تصادفی در عملکرد این الگوریتم، در هر بار اجرای این برنامه، مقدار purity score می‌تواند کمتر یا بیشتر از این مقدار شود، ولی در هر صورت، این الگوریتم عملکرد خوبی در خوشبندی دیتاست Iris دارد. یکی از دلایل این امر به تعداد نسل‌های گسترش یافته برمی‌گردد، با توجه به این‌که بهترین کروموزوم هر نسل، نسبت به نسل‌های قبلی مقدار fitness کمتری دارد، پس هر چقدر تعداد نسل‌های گسترش یافته بیشتر شود، الگوریتم ما نیز در خوشبندی بهتر عمل می‌کند. اما باید به این نکته توجه داشت که افزایش تعداد نسل، یا پیچیده‌تر کردن توابع مربوط به الگوریتم ژنتیک علیرغم بهبود عملکرد الگوریتم ژنتیک، ممکن است حافظه و زمان بیشتری را مصرف کند.

فصل چهارم

لینک کد گزارش

لینک کد گزارش

کد خوشه‌بندی دیتاست Iris به دو روش K-Means و الگوریتم ژنتیک در Google Colab نوشته شده و لینک آن در زیر قابل دسترسی است:

[لینک کد گزارش ۶ در Google Colab](#)

فصل پنجم

جمع‌بندی و نتیجه‌گیری

جمع‌بندی و نتیجه‌گیری

در این مقاله، ما دو روش خوش‌بندی K-Means و الگوریتم ژنتیک را بر روی دیتاست Iris که شامل اطلاعات درباره گونه‌های مختلف گل زنبق است، اعمال و مقایسه کردیم. ما از معیار purity score برای مقایسه دقت هر دو روش با توجه به برچسب‌های واقعی داده‌ها استفاده کردیم. این مقدار برای خوش‌بندی با الگوریتم ژنتیک تقریباً ۰.۹ و برای خوش‌بندی با الگوریتم K-Means تقریباً ۰.۸۳ شد. نتایج نشان داد که در اینجا الگوریتم ژنتیک نسبت به الگوریتم K-Means عملکرد بهتری دارد و می‌تواند خوش‌هایی با همبستگی داخلی بالا و همبستگی بین خوش‌های پایین تشکیل دهد. این می‌تواند به خاطر نوع تعریف ما از توابع مربوط به الگوریتم ژنتیک و همچنین تعداد نسل‌های تولید شده باشد. واضح است که هر چقدر تعاریف این نوع توابع دقیق‌تر و از لحاظ پیچیدگی معنادارتر باشند، عملکرد الگوریتم نیز بهبود می‌یابد و نتایج بسیار بهتری را ارائه می‌دهد. در سیر تکاملی الگوریتم ما، مقدار Fitness بهترین کروموزوم در هر نسل کمتر شد و این بدان معنی است که الگوریتم با پیشروی در نسل‌های بعدی، دیتاست را دقیق‌تر و بهتر خوش‌بندی می‌کند. هر چقدر تعاریف توابع پیچیده‌تر و تعداد نسل‌های تولید شده نیز بیشتر باشد، الگوریتم حافظه و زمان بیشتری را مصرف می‌کند.

منابع

"Faradars," [Online]. Available: <https://b.fdrs.ir/1l4>.

"Faradars," [Online]. Available: <https://b.fdrs.ir/2az>.

"Maktabkhooneh," [Online]. Available: <https://maktabkhooneh.org/mag/genetic-algorithm-in-artificial-intelligence/>.

"Wikipedia," [Online]. Available: https://en.wikipedia.org/wiki/Genetic_algorithm.

"Geeks," [Online]. Available: <https://www.geeksforgeeks.org/crossover-in-genetic-algorithm/>.

"Geeks," [Online]. Available: <https://www.geeksforgeeks.org/genetic-algorithms/>.

"UCIrvine," [Online]. Available: <https://archive.ics.uci.edu/dataset/53/iris>.